



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目： 基于大模型文档知识抽取的领域知识图谱增量构建
作者： 陈俊臻，王淑营，罗浩然
网络首发日期： 2025-11-04
引用格式： 陈俊臻，王淑营，罗浩然. 基于大模型文档知识抽取的领域知识图谱增量构建[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20251104.1244.010>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于大模型文档知识抽取的领域知识图谱增量构建

陈俊臻¹, 王淑莹¹⁺, 罗浩然²

1.西南交通大学计算机与人工智能学院, 成都 611756

2.北京邮电大学计算机学院, 北京 100876

+ 通信作者 E-mail: wangshuying@swjtu.edu.cn

摘要: 针对工业领域知识图谱构建中面临的标注样本稀缺、文档多源异构、语义结构复杂等挑战, 本文提出一种基于大型预训练语言模型的领域知识图谱增量构建方法 LLM-KG。该方法首先利用 GPT-4 模型自动生成高质量的标注样本, 降低人工标注成本的同时提升训练数据的覆盖性与准确性; 随后, 借助 LoRA(Low-Rank Adaptation) 技术对轻量级语言模型进行领域微调, 实现对领域文档中实体与关系的高精度抽取。为提升新增实体和关系的对齐质量, LLM-KG 引入语义块划分机制, 并结合向量数据库进行 Top-k 实体召回, 最终由大语言模型对召回结果进行语义一致性判断与筛选, 从而实现更加准确的实体融合与关系补全。在公开数据集 DDI 及风电装备数据集上进行了实验验证, 结果表明, LLM-KG 在准确率、召回率和 F1 值上均优于对比方法, 展现出良好的领域适应性与增量构建能力。

关键词: 知识图谱; 大模型微调; 文档信息抽取; 增量构建

文献标志码:A 中图分类号:TP3 doi: 10.3778/j.issn.1002-8331.2504-0398

Domain Knowledge Graph Incremental Construction via Large Language Model-based Document Extraction

CHEN Junzhen¹, WANG Shuying¹⁺, LUO Haoran²

1.School of Computing and Artificial Intelligence, Southwest Jiaotong University, Chengdu 611756, China

2.School of Computer Science, Beijing University of Posts and Telecommunications, Beijing 100876, China

Abstract: To address challenges in domain-specific knowledge graph construction, such as scarcity of annotated samples, multi-source heterogeneous documents, and complex semantic structures, this paper proposes an incremental construction method for domain knowledge graphs, termed LLM-KG, based on large pre-trained language models. In this method, high-quality annotated samples are first automatically generated using the GPT-4 model, reducing manual annotation costs while enhancing the coverage and accuracy of training data. Subsequently, a lightweight language model is fine-tuned using the Low-Rank Adaptation (LoRA) technique to enable high-precision extraction of entities and relations from domain texts. To further improve the alignment quality of newly extracted entities and relations, a semantic block partitioning mechanism is introduced. Top-k entity candidates are retrieved through a vector database, and semantic consistency filtering is performed by the large language model to ensure accurate entity linking and relation completion. Experimental evaluations on the public DDI dataset and a self-constructed wind power equipment dataset demonstrate that LLM-KG outperforms baseline methods in terms of precision, recall, and F1-score, exhibiting strong domain adaptability and effective incremental construction capability.

Key words: Knowledge Graph; Large Model Fine-tuning; Document Information Extraction; Incremental Construction

基金项目: 国家重点研发计划项目(2022YFC3005203), 四川省重大科技专项项目(2022ZDX0003)。

作者简介: 陈俊臻(2000-),男,硕士研究生,CCF 学生会员,研究方向为知识图谱协同大模型;王淑莹(1974-),通信作者,女,博士,教授,研究方向为自然语言处理;罗浩然,男,博士研究生,研究方向为自然语言处理。

随着人工智能与自然语言处理技术的不断进步,知识图谱(Knowledge Graph, KG)作为结构化表示海量知识的核心手段,已广泛应用于推荐系统^[1]、智能问答^[2]、智能运维^[3]等多种智能化场景。通过对实体及其关系的建模,知识图谱有效支撑了复杂语义问题的解析与智能推理,逐步成为认知智能的重要基础设施。

在风电装备、航空航天、智能制造等典型工业领域中,知识图谱的构建不仅有助于打通信息孤岛、提升知识管理与复用效率,还能为故障诊断、风险预测与运维决策等下游任务提供关键的知识支撑。然而,相较于通用领域,工业知识图谱构建面临更为严峻的挑战,主要体现在以下三个方面:①标注样本稀缺:工业领域数据标注工作量大、成本高昂,高质量领域标注样本极其有限,制约实体和关系抽取模型的训练与泛化能力;②文档多源异构:工业知识分布于设计文档、运行报告、维修手册等多种格式与结构复杂的文本资料中,不同文档间存在知识冗余、命名歧义和表达不一致,极大增加了文档解析与语义统一的难度;③语义结构复杂:工业文本中包含大量专业术语、缩略词与符号表达,且常见实体嵌套与关系链结构,传统命名实体识别与关系抽取方法难以准确捕捉复杂语境下的语义信息。

近年来,大型预训练语言模型(Large Language Models, LLMs)的快速发展为知识图谱构建带来了新的突破^[4]。以 GPT-4、ChatGLM 等为代表的模型具备卓越的语言理解与生成能力,能够在少量甚至零样本条件下完成复杂语言任务。借助 LoRA^[5]等高效微调技术,轻量化的大模型能够快速适配工业领域术语体系^[6],在提升抽取泛化能力、鲁棒性和效率方面展现出独特优势,特别适用于长文本下的结构化知识抽取。

尽管已有部分研究尝试将大语言模型应用于三元组抽取任务,但在知识融合与增量构建阶段仍存在诸多不足:当前方法多依赖浅层表征匹配进行实体对齐,缺乏语义一致性判断机制;抽取结果验证流程不完善,难以保障图谱构建的完整性与准确性,尚不能满足工业应用对高质量知识图谱的需求。

为此,本文提出一种面向工业领域的知识图谱增量构建方法——LLM-KG,融合轻量化大模型微调与语义一致性驱动的实体关系对齐机制,旨在提升图谱构建的准确性与自动化程度。主要贡献如下:

(1) 基于 GPT-4 生成高质量标注样本,结合 LoRA 技术对轻量化大模型进行高效领域微调,形成从数据生成到模型优化的闭环训练机制,有效缓解工业场景下标注样本稀缺问题,并提高模型对复杂语义结构的理解能力。

(2) 提出基于语义完整性的信息块划分机制,以更细粒度地表示上下文语义单元,实现异构文档的统一结构化表达,并结合向量数据库实现 Top-k 候选实体召回,在降低召回噪声的同时显著提高跨文档实体的覆盖率与融合准确率。

(3) 在知识融合阶段引入领域轻量化模型对候选实体之间的语义相似度与一致性进行深层分析与判断,突破传统基于字符串或浅层表示匹配的局限,提升实体和关系对齐的准确性与结构完整性,解决多源文档知识冗余、命名歧义和表达不一致问题。

1. 相关工作

领域知识图谱是实现语义理解与知识推理的核心基础设施,在医疗^[7]、教育^[8]、军事^[9]及智能制造^[10]等领域发挥着重要作用。随着自然语言处理技术的发展,其构建方法经历了从规则驱动到深度学习,再到大模型驱动的演进,逐步提升了知识抽取的自动化与智能化水平。

早期的知识图谱构建主要依赖人工规则和模板匹配,如基于规则的命名实体识别和关系抽取方法^[11-12]。虽然这类方法具有可解释性强、可控性高的优点,但面对大规模、多样化文本时,其扩展性差、人工成本高的问题日益突出^[13]。

随着深度学习的兴起,基于神经网络的图谱构建方法成为主流。卷积神经网络(Convolutional Neural Network, CNN)^[14]、循环神经网络(Recurrent Neural Network, RNN)^[15]以及双向长短期记忆网络与条件随机场的结合(Bidirectional Long Short-Term Memory with Conditional Random Fields, BiLSTM-CRF)^[16-17]等模型显著提升了语义建模能力^[18],而图神经网络(Graph Neural Network, GNN)凭借对图结构的天然适配性,进一步优化了复杂关系的建模能力^[19]。然而,这些方法仍依赖大量标注数据,训练和推理成本较高,且难以适应动态更新的应用场景^[20]。

近年来,以 BERT、GPT、T5 等为代表的大规模预训练语言模型(Pre-trained Language Model, PLM)凭借强大的语义理解和推理能力,推动了知识图谱构建的新一轮变革。此类模型通过自监督学习获取通用语义表示,能够在低资源条件下实现高质量的实体和关系抽取^[21]。例如:Zhang 等人^[22]提出的 LinkNER 框架,将本地精调 NER 模型与大型语言模型(如 GPT-3.5 与 Llama 2)通过不确定性驱动机制相结合,实现模型间的互补协同;Hu 等人^[23]针对临床领域的 NER 任务,系统评估了 GPT-3.5 和 GPT-4 在不同提示设计条件下的表现,并提出了一套基于任务定义、错误分析与少样本学习相结合的提示优化策略,验证了 LLMs 在无需大规模标注数据情况下仍然可实现高质量实体识别的能力;Dagdelen 等人^[24]进一步探索了通过对 GPT-3 与 LLaMA 2 等大模型进行微调,实现复杂科学文本中结构化信息的自动抽取;De 等^[25]以 RoBERTa 为基础提出了 AgNER-BERTa 和 AgRE-BERTa 模型,在农业领域数据上进行专门微调,以缓解标注数据不足的问题。

当前,大模型驱动的知识图谱构建研究已取得显著

进展。例如：Pimpalgaonkar 等人^[26]采用微调后的 Phi3-3.8B 用于实体与关系三元组的联合抽取，实现在本地高效构建图谱；XIE 等人^[27]对开源中文大模型 ChatGLM2-6B 进行领域语料微调，结合思维链与自我验证方法设计高质量 Prompt，从而自动提取领域实体与关系，构建结构化知识图谱；ZHANG 等人^[28]通过设计 zero-shot Prompt，引导大语言模型直接对故障运维数据进行概念建模与知识抽取，实现无监督下的知识图谱生成，同时采用迭代策略不断完善图谱结构；DONG 等人^[29]通过构建施工安全本体作为模型抽取模板，结合文本与图片数据，利用大语言模型实现对多模态数据的统一抽取，并以三元组形式构建知识图谱，同时引入 Prompt 技术与本体驱动机制以增强抽取准确性与一致性。此外，知识蒸馏和增量学习技术的引入进一步增强了模型的动态更新能力^[30]。

然而，现有方法仍面临两大挑战：

(1) 实体对齐与语义冗余问题：传统方法依赖词向量相似度计算，难以准确识别语义一致但表述不同的实体，导致图谱中存在冗余或冲突的三元组^[31]。

(2) 动态更新能力不足：现有系统大多缺乏高效的增量更新机制，难以适应多源异构知识的持续抽取融合。

尽管 iText2KG 等框架尝试优化增量构建^[32]，但其仍依赖向量相似度计算，且对闭源大模型的强依赖性带来了高成本和可控性不足的问题。

针对上述挑战，本文提出了一种融合大模型语义理解与增量式知识构建的创新方法。具体而言，利用 GPT-4 自动生成高质量标注数据，并基于 LoRA 技术对轻量级模型（如 ChatGLM3-6B、Llama3-8B）进行高效微调，以降低训练成本。同时，设计“Top-K 向量召回+大模型语义一致性判断”的双阶段对齐机制，先通过向量数据库粗筛候选实体，再调用大模型进行细粒度语义验证，从而提升知识抽取的准确性和鲁棒性。

2. LLM-KG 模型

2.1 模型总体框架概述

LLM-KG 是一个面向领域知识图谱动态构建的通用框架，基于轻量化大语言模型（如 ChatGLM3-6B、Llama3-8B），结合 LlamaFactory 框架和 LoRA 技术，实现对领域任务的高效适配与端到端构建。该框架采用三阶段处理流程，整体结构如图 1 所示，由领域文档解析、实体增量提取和关系增量提取三大核心模块组成，构建从原始文档到高质量知识图谱的闭环流程。其中：




图 1 LLM-KG 模型框架

Fig.1 LLM-KG model framework

领域文档提取模块面向多源异构的领域文档，首先通过预定义的文档解析模板实现常见文档类型的解析，融合 GPT-4 教师模型的深层语义解析能力，生成高质量标注样本，结合 LoRA 技术对轻量级大模型进行高效领域微调，通过语义分块与内容结构统一机制，将格式各异、

结构复杂的原始文本转化为规范化的结构化语义块，解决领域标注样本稀缺与文档异构问题。

领域实体增量提取模块基于微调的领域轻量级大模型，融合向量召回、Top-k 语义检索及语义一致性判别机制，以提升术语表达多样、上下位嵌套和语义歧义等复

杂语义结构下跨文档实体的覆盖率与融合准确率。

领域关系增量提取模块依托微调领域轻量模型的上下文理解能力,结合余弦相似度计算与多轮语义一致性判别策略,精准抽取实体间关系并实现语义融合,通过引入多轮匹配与关系类型归并机制,提升复杂语义结构下关系准确抽取及来自多源文档实体关系三元组的增量抽取及融合质量。

2.2 领域文档提取模块

本模块旨在实现从原始领域文档到结构化知识的自动转换，重点提升对长文本的处理能力以及知识抽取的准确性与效率。针对长文本中常见的语义离散、信息冗余等问题，本文设计了一种结合知识蒸馏与自适应分块机制的抽取流程，如图 2 所示。




图 2 领域文档提取示意图

Fig.2 Illustration of Domain Document Extraction

(1) 领域文档预处理

系统首先接收原始的非结构化领域文档，并执行分页、段落识别与语义分块等预处理操作，将整篇文档划分为若干具有明确语义边界的结构化语义块。为应对工业领域文档来源多样、格式多变的实际特点，本文针对常见文档类型设计了相应的预处理策略，具体见表 1。

表 1 常见领域文档格式的预处理方法

Table 1 Preprocessing Methods for Common Domain Document Formats

文档类型	预处理方法
PDF	逐页提取文本内容，同时保留页码、章节编号等结构化元数据信息，用于后续语义定位与结构建模，构建结构化语义块
TXT	依据段落换行符进行逻辑切分，将文档划分为模拟页面结构的段落单元，为每段内容标注顺序索引，构建结构化语义块
WORD	使用 <code>python-docx</code> 解析器读取段落内容，并提取标题层级、编号、段落结构等文档元信息，构建结构化语义块
EXCEL	利用 <code>openpyxl</code> 工具读取表格内容，结合列名与上下文注释信息，将表格转换为文本片段，构建结构化语义块
图像类	集成 <code>PaddleOCR</code> 引擎进行文字识别，并结合 <code>LayoutLM</code> 模型识别标题、段落、表格等逻辑结构，划分为结构化语义块

此外，系统对内容跨度较大的跨主题段落引入了自动语义细化机制，将其划分为粒度更小的语义单元，每个单元聚焦于一个具体概念或事件，便于后续模型更精准地识别出实体及其之间的语义关系。

(2) 教师模型驱动的语义解析

在完成预处理后，系统引入具备强语言理解与知识推理能力的教师模型 GPT-4，结合领域知识图谱驱动的提示模板 (prompt template)，对语义块内容进行深度解析。该阶段融合了大语言模型在自然语言理解方面的优势，同时借助领域先验知识进行约束，从而提升核心信息单元的抽取质量。具体而言，教师模型依据预定义的抽取模式，识别出如设备部件、运行参数、故障现象、原因分析等实体及其关系，并将其组织为三元组形式。

为保障后续训练的一致性与泛化性，教师模型所生成的三元组结构被组织为符合 Alpaca 微调格式的数据样本，形成标准化的领域知识微调数据集，以方便后续实验中基于 LlamaFactory 进行统一的微调操作。

LlamaFactory 是一个面向开源大语言模型优化设计的高效微调框架，支持多种主流模型（如 LLaMA、ChatGLM 等）的指令微调与领域适配，具备良好的模型兼容性与扩展性，能够在保证训练速度与显存利用率的同时，显著简化轻量模型的微调流程。基于该框架，本研究完成了风电装备领域知识抽取模型的高效微调训练。图 3 展示了针对风电装备领域所生成的微调数据。

你是风电装备领域的专家，任务是从下面的原始文本中提取出与风电设备相关的【头实体】-【关系】-【尾实体】三元组，并生成符合微调数据集格式的 JSON 输出。提取的【头实体】、【关系】、【尾实体】应填充到输出中的对应部分，请根据文本内容准确提取三元组并确保输出格式正确。

输入文本：
【原始文本】
输出格式：
{ "instruction": "根据描述性文档块提取主要三元组并生成输出",
 "input": "【在此插入原始文本】",
 "output": [{ "subject": "【头实体】", "relation": "【关系】", "object": "【尾实体】" }] }
具体示例:...

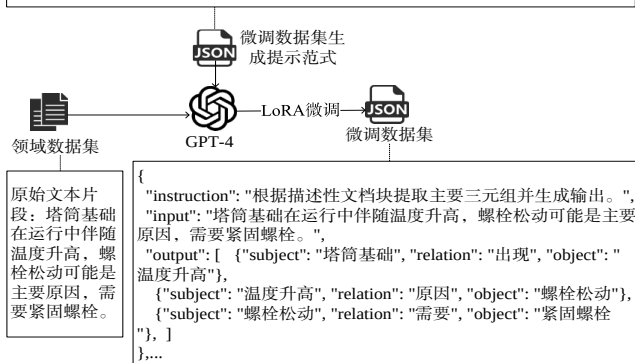


图 3 微调数据集生成示意图

Fig.3 Illustration of Fine-tuning Dataset Generation

(3) 微调模型构建与部署

利用上述高质量三元组数据集，系统对轻量化大语言模型进行微调训练，采用 LoRA 技术对 ChatGLM3-6B 和 LLaMA3-8B 进行优化。在有效降低计算资源消耗和显存占用的同时，模型依然保持了良好的抽取性能。最

终,系统综合评估微调模型在精度、召回率与响应速度等多个指标上的表现,选取性能最优的模型部署至实际文档解析任务中,实现高效稳定的实体与关系抽取。

(4) 文档结构化抽取与多轮补全机制

在结构化抽取阶段,系统以原始文档及其对应的提示模板作为输入,调用集成 LangChain 的 JSON 结构解析器,输出具备语义结构的语义块。若首轮抽取结果存在信息缺失或不完整,系统将自动触发多轮补全机制,对缺失信息进行迭代式识别与补全。每轮抽取得到的内容会与历史结果进行融合与归并,最终生成语义完整、内容一致的结构化文档块,并存储至数据库中,为后续实体与关系抽取模块提供统一、高质量的输入基础。

2.3 领域增量实体提取模块

本模块旨在对领域文档提取模块输出的结构化语义块进行逐条解析,基于增量机制实现领域实体的动态识别与全局实体集合的持续维护。相较于传统依赖人工标注或规则模板的实体识别方式,本文引入微调后的轻量领域大模型进行实体抽取,不仅能显著降低人工成本和计算资源消耗,也能提升模型对领域术语的理解与泛化能力。

为确保新识别实体与已有实体的语义一致性,系统引入向量数据库(如 FAISS)实现候选实体与全局实体的相似度计算,并结合 Top-k 召回策略筛选潜在匹配项。随后,借助大模型对实体对之间的语义一致性进行判别,确保新旧实体在语义上的协调与统一。整体处理流程如图 4 所示。




图 4 领域增量实体抽取示意图

Fig.4 Illustration of Incremental Extraction of Domain Entities

(1) 实体提取提示范式设计

在执行实体抽取任务前,系统需结合领域知识图谱中定义的本体结构,设计实体提取范式(Prompt Paradigm),用于指导大模型按照指定实体类型进行分类识别。该范式采用“角色设定+任务要求+示例输入”的

提示结构,明确抽取实体的类别范围,并提供结构化输出示例,从而增强模型输出结果的一致性与可控性。

以风电装备运维领域为例,其本体中常见实体类型包括但不限于:故障部件、故障原因、维护措施以及运行参数。表 2 展示了实体提取范式的具体构造示例。

表 2 实体提取范式示例

角色说明	任务要求	示例
作为风电领域的故障分析专家,你的任务是从给定的文本中精准提取符合指定类别的相关实体。	实体类型要求: 故障部件 : 齿轮箱、机组、风速传感器等; 故障原因 : 润滑油污染、过载、材料老化; 维护措施 : 更换润滑油、清理齿轮箱等; 运行参数 : 温度、振动、电流、转速等; 故障现象 : 异常噪音、过热报警、响动等; 请严格按照给定的实体类别要求进行信息提取,仅提取符合这些类别的实体,并确保结果的准确和完整。	输入文本 : 风电机组的齿轮箱因润滑油污染导致温度异常,需更换润滑油。 分析输出 : 故障部件: 齿轮箱; 故障原因: 润滑油污染; 故障现象: 温度异常; 维护措施: 更换润滑油。

(2) 全局实体集的初始化

在初始阶段,系统首先使用微调后的领域轻量大型对首个文档 d_0 进行实体抽取,得到初始全局实体集 E 。与其他文档不同, d_0 是一个预处理后的文档,确保其提取出的实体集合中不包含重复实体,从而能够作为初始化全局实体集 E 的基础。具体而言,对于 d_0 中的每个局部实体 $e_i \in E_{d_0}$, 直接加入全局实体集合 E , 以确保初始实体集合的唯一性和完整性。

(3) 实体的动态融合与更新机制

对于后续文档集合中的每个文档 d , 提取其局部实体集合 E_d , 对于局部实体 $e_i \in E_d$, 更新机制为: 通过向量匹配、Top-k 召回与大模型一致性判断,动态对比已有全局实体集合,判断新识别实体是否为已存在概念的变体或补充,确保图谱语义边界不断拓展,实现方法如下:

①完全匹配判断: 如果 e_i 在全局实体 E 中已经存在(即完全匹配),则直接跳过,无需进行后续计算。

②相似度计算: 如 e_i 不在 E 中,使用余弦相似度计算其与全局实体集合 E 之间的相似度,并返回 top-k 个候选匹配集,计算方法见公式(1):

$$\text{top}_k(e_i, E) = \{(e_j, e_i) | e_j \in E, \cos(e_i, e_j) \text{ 最高的 } k \text{ 个匹配对}\} \quad (1)$$

③余弦相似度计算,方法见公式(2):

$$\cos(e_i, e_j) = \frac{\mathbf{v}_{e_i} \cdot \mathbf{v}_{e_j}}{\|\mathbf{v}_{e_i}\| \|\mathbf{v}_{e_j}\|} \quad (2)$$

式中 $\mathbf{v}_{e_i}$ 和 $\mathbf{v}_{e_j}$ 分别表示局部实体 e_i 和全局实体 e_j 的向量表示。 $\mathbf{v}_{e_i} \cdot \mathbf{v}_{e_j}$ 表示两实体向量的点积,用于衡量它们的方向相似度; $\|\mathbf{v}_{e_i}\|$ 和 $\|\mathbf{v}_{e_j}\|$ 分别表示 $\mathbf{v}_{e_i}$ 和 $\mathbf{v}_{e_j}$ 的欧几里得范数,用于归一化计算。

④实体匹配判断: 利用领域轻量大型 LLM 对实体对进行匹配判断,提示大模型匹配成功返回 1,失败返

回 0 作为标志, 计算方法见公式 (3):

$$\text{LLM}(e_i, e_j) = \begin{cases} 1, & \text{若 } e_i \text{ 与 } e_j \text{ 匹配} \\ 0, & \text{若 } e_i \text{ 与 } e_j \text{ 无法匹配} \end{cases} \quad (3)$$

⑤全局实体更新: 若 e_i 所有匹配判断都失败 (即大模型判断实体对值都为 0), 则认为该实体为新实体, 加入全局实体集, 计算方法见公式 (4):

$$E = E \cup \{e_i | e_i \in E_d, \forall (e_i, e_j) \in \text{top}_k(e_i), \text{LLM}(e_i, e_j) = 0\} \quad (4)$$

通过上述增量融合机制, 系统能够动态吸收文档中不断出现的新实体, 支持实体集合的持续扩展、去重融合与语义对齐。

2.4 领域增量关系提取模块

本模块以领域文档提取模块构建的语义块集合与领域增量实体提取模块生成的全局实体集合为输入, 旨在实现领域关系的增量抽取与融合。具体地, 系统将结构化 JSON 语义块与当前全局实体集共同作为微调后的轻量级大语言模型的上下文输入, 借助更完整的语义环境执行关系识别与三元组抽取任务, 从而显著提升抽取结果的准确性与覆盖率。整个处理流程如图 5 所示。

为实现对语义上相同或相近关系的准确归并, 并在关系本体体系动态扩展的同时识别潜在新关系类型, 系统沿用了基于余弦相似度的关系匹配策略。该策略支持在当前全局关系集中选取与目标关系语义最相关的 Top-k 候选集, 并结合大语言模型的语义一致性判断机制, 完成关系的自动归并、类型归约与新增识别, 从而有效避免冗余关系的扩张与图谱语义结构的混乱。




图 5 领域增量关系提取示意图

Fig.5 Illustration of Incremental Extraction of Domain Relations

(1) 关系抽取提示范式设计

为规范关系抽取任务的输出格式并提升其准确性, 系统基于领域知识本体设计了标准化的提示范式, 包含角色设定、任务说明以及输入输出示例, 辅助大模型理解任务目标并输出符合结构要求的三元组结果。表 3 展示了风电运维领域中的典型关系抽取提示范式。

表 3 关系抽取范式示例

角色说明	任务要求	示例
作为风电领域的故障分析专家, 请你完成下面的任务。	请根据上一步提取的实体, 抽取关系, 构造“(主体, 关系, 客体)”关系三元组, 关系类型优先使用以下类别, 如有类似的关系则合并为以下类型: 发生: 表示故障或异常发生的位置; 定位: 表示对故障的诊断或判定; 需要检修: 表示设备或部件需要维修。	输入文本: 风电机组的齿轮箱由于润滑油污染导致温度异常, 需更换润滑油。 已识别实体: 故障部件: 齿轮箱; 故障原因: 润滑油污染; 故障现象: 温度异常; 维护措施: 更换润滑油。 元组输出: (齿轮箱, 发生, 润滑油污染), (齿轮箱, 需要检修, 更换润滑油), (温度异常, 定位, 润滑油污染)。

(2) 全局关系集的初始化

在系统初始阶段, 首先使用微调后的大模型对首个文档 d_0 进行处理, 并结合全局实体集合 E 进行关系抽取, 得到初始全局三元组集合和全局关系集合 T 。 d_0 经过预处理, 以确保其提取出的关系集合符合领域本体的定义, 并能够作为初始化全局关系集合 R 的基础。具体而言, 对于 d_0 中的每个局部实体 $r_i \in R_{d_0}$, 直接加入全局关系集合 R , 每个三元组 (h_i, r_i, t_i) 直接加入全局三元组, 以保证初始关系集合的完整性。

(3) 增量关系融合与匹配机制

对于后续语义块集合中的每个语义块 d , 提取其局部三元组集合 T_d 并进行增量匹配。对于局部关系 $r_i \in R_d$, 判断新识别关系是否为已存在关系的变体或补充, 以支持关系的持续扩展和演化, 其实现方法如下:

①完全匹配判断: 如果 (h_i, r_i, t_i) 在全局三元组集合 T 中已经存在 (即完全匹配), 则直接跳过, 无需进行后续计算。

②相似度计算: 若 r_i 不在 R 中, 使用余弦相似度计算其与全局实体集合 R 之间的相似度, 并返回 top-k 个候选匹配集合, 计算方法如下式 (5):

$$\text{top}_k(r_i, R) = \{(r_j, r_i) | r_j \in R, \cos(r_i, r_j) \text{ 最高的 } k \text{ 个匹配对}\} \quad (5)$$

③关系匹配判断: 利用领域轻量级大模型 LLM 对关系对进行语义判断, 提示大模型匹配成功返回 1, 失败返回 0, 计算方法见下式 (6):

$$\text{LLM}(r_i, r_j) = \begin{cases} 1, & \text{若 } r_i \text{ 与 } r_j \text{ 匹配} \\ 0, & \text{若 } r_i \text{ 与 } r_j \text{ 无法匹配} \end{cases} \quad (6)$$

若 r_i 匹配成功, 则替换关系 r_i 为 r_j , 映射如式 (7):

$$(h_i, r_i, t_i) \rightarrow (h_i, r_j, t_i) \quad (7)$$

若 r_i 所有匹配判断都失败 (即 LLM 判断关系对均返回 0), 则认为该关系为潜在关系类型, 加入全局关系集, 计算方法如式 (8):

$$R = R \cup \{r_i\} \quad (8)$$

并将该三元组加入全局三元组集合, 计算方法如下:

$$T = T \cup \{(h_i, r_i, t_i)\} \quad (9)$$

通过上述增量关系融合机制，系统能够在知识图谱持续构建过程中，自动归并重复关系、扩展关系类型体系、增强语义一致性，从而构建出结构合理、语义清晰、动态可演化的高质量领域知识图谱。

3. 实验结果及分析

3.1 本文所用数据集

3.1.1 风电装备数据集

本研究所采用的风电装备数据集(Wind Power Equipment Dase,WPED)来源于某企业提供的风电机组运行与故障分析数据，涵盖风电机组的关键部件、运行状态、故障类型等，广泛应用于风电设备运维、故障诊断等研究。该数据集通过实际设备监测数据与运维记录构建，包含风机叶片、齿轮箱、主轴承、变桨系统等核心部件的运行状态及故障信息。其详细统计信息如表 4 所示，抽取案例如表 5 所示。

表 4 WPED 信息统计

Table 4 Statistical Information of WPED

数据集名称	微调数据量	生成三元组数
风电装备数据集	7234	28471

表 5 WPED 抽取示例

Table 5 Extraction Example from the WPED

文档文本	抽取的三元组
检测算法识别出主轴承润滑异常，影响风机运行稳定性，需要更换润滑系统组件。	(检测算法, 发现, 主轴承润滑异常) (主轴承润滑异常, 影响, 风机运行稳定性) (轴承润滑异常, 需要, 润滑系统组件)
叶片根部连接螺栓断裂，属于故障事件，影响风机运行安全	(叶片根部, 故障事件, 连接螺栓断裂) (连接螺栓断裂, 影响, 风机运行安全)
变桨系统伺服电机故障，影响风机桨叶角度调整，需提交 NCR 单审批。	(变桨系统, 故障事件, 伺服电机故障) (伺服电机故障, 影响, 风机桨叶角度调整) (NCR 单, 记录, 伺服电机故障)

3.1.2 公开域数据集

为验证模型在通用领域的泛化能力，本文选用广泛用于生物医学文本挖掘的 DDI 数据集(Drug-Drug Interaction Dataset)进行对比实验。该数据集由药物相互作用任务组织者提供，涵盖来自 DrugBank 和 MedLine 的高质量文献，包含大量药物实体及其交互关系，是关系抽取研究的标准测试集。数据统计见表 6，三元组抽取示例如表 7 所示。

表 6 DDI 数据集信息统计

Table 6 Statistical information of the DDI dataset

数据集名称	文档数	实体数量	关系数量
DDI	1017	18491	5021

表 7 DDI 提取数据实例

Table 7 Example of extracted data from the DDI dataset

文档文本	抽取的三元组
In female rats, neonatal quinpirole treatment enhanced amphetamine locomotor sensitization compared with quinpirole-free controls sensitized to amphetamine.	("quinpirole", "effect", "amphetamine")
patients receiving lithium and Neulasta should have more frequent monitoring of neutrophil counts.	("lithium", "advise", "Neulasta")
Cholestyramine-Concomitant intake of cholestyramine and vitamin K may reduce the absorption of vitamin K.	("cholestyramine", "mechanism", "vitaminK")

3.2 基线模型及评价指标

为了评估提出的 LLM-KG 模型的有效性，本文选择近 2 年内具有开源构建方法进行比较，主要包括：

①Sciphi Triplex^[15](2024)：Triplex 是由 SciPhi.AI 开发的，用于从非结构化数据创建知识图谱，它的工作原理是从文本或其他数据源中提取三元组。

②COT^[18](2024)：通过引导大模型逐步推理，将复杂任务分解为一系列简单的子任务，从而提高抽取的准确性和逻辑性。在三元组任务中，首先进行实体抽取，然后再抽取文本块之间的关系，进而提取三元组。

③直接提示^[17](DP,Direct Prompt)(2024)：采用大语言模型进行直接信息提取。这种方法依赖于模型预训练的知识和能力，通过文本直接生成抽取结果。

④领域微调提示^[16](DFP,Domain Fine-tuning Prompt)(2024)：首先，利用领域知识对大模型进行微调，然后，对微调之后的大语言模型进行提示抽取。

在三元组抽取过程之中，有且仅当头实体、关系、尾实体均被识别正确时才视为识别成功。主要错误类型有头实体或者尾实体错误，或者实体预测准确但是关系错误。具体评测指标包括：精确率、召回率、F1 值，计算方法如式(10)-(12)所示：

$$Precision = \frac{\text{正确识别出的三元组个数}}{\text{模型识别出来的三元组个数}} \quad (10)$$

$$Recall = \frac{\text{正确识别出的三元组个数}}{\text{所有的三元组个数}} \quad (11)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \times 100\% \quad (12)$$

3.3 实验设置及环境

(1) 实验环境

实验在 Windows 11 专业版操作系统下进行，使用 Python 3.10 作为编程语言。硬件配置采用 NVIDIA RTX A6000 显卡(48GB 显存)。

(2) 模型配置

领域轻量级大模型选取 Llama3-8B 和 ChatGLM3-6B 作为基础模型，基于 Llama-factory 框架进行微调。具体参数设置如下表 8 所示。

表 8 模型参数设置

Table 8 Model Parameter Settings

参数名称	参数值
微调方法	采用 LoRA (Low-Rank Adaptation) 技术
批量大小	16
学习率	1e-5
LoRA 秩	64
优化器	AdamW 算法

(3) 数据划分


为保证不同模型间在不同数据集上的公平对比, 实验均采用统一的数据划分方式: 80%作为训练集, 10%作为验证集, 10%用于测试。

3.4 实验结果及分析


3.4.1 微调大模型选择实验

通过对 Llama3-8B 与 ChatGLM3-6B 在两个数据集上的表现进行对比, 结果如下:

(1) 在 WPED 风电装备数据集上: 训练过程稳定性如图 6 所示, Llama3-8B 表现出更平滑的训练曲线, 图 7 显示 Llama3-8B 在得分上较 ChatGLM3-6B 有明显优势。



(a) Llama3-8B模型训练



(b) ChatGLM3-6B模型训练

图 6 风电装备数据上的模型训练

Fig.6 Model Training on Wind Power Equipment Data






图 7 模型在 WPED 的分数

Fig.7 Performance Scores of Model on WPED

(2)在 DDI 公开数据集上: 图 8 表明 Llama3-8B 具有更快的收敛特性, 图 9 结果显示 Llama3-8B 的准确率明显高出 ChatGLM3-6B。



(a) Llama3-8B模型训练



(b) ChaGLM3-6B模型训练

图 8 DDI 上的模型训练图

Fig.8 Training Curve of Model on the DDI




图 9 模型在 DDI 上的分数图

Fig.9 Performance Scores of Model on the DDI

基于上述实验结果，选择 Llama3-8B 作为基础模型进行后续实验，主要基于以下优势：①跨领域适应性：在领域数据和公开数据上均表现优异；②实体关系识别精度：展现出更精准的抽取能力；③训练稳定性：损失曲线波动更小，收敛性更好。

3.4.2 专业域实验结果

将本文的模型与基准模型在专业域风电装备数据集 WPED 上的三元组完全匹配精确率、召回率以及 F1 值的比较，最后得出的结果如下表 9 所示。

表 9 专业域模型效果对比

Table 9 Comparison of domain-specific model performance

数据集	构建方式	精确率	召回率	F1 值
WPED	DP	44.36	35.40	39.36
	COT	56.42	47.19	51.42
	DFP	81.15	71.79	76.15
	Sciphi Triplex	57.28	48.11	52.28
	LLM-KG (本文)	83.19	73.80	78.19

对专业域的模型效果进行分析，LLM-KG 在 WPED 取得了最优表现，精确率、召回率和 F1 值分别为 83.19%、73.80%和 78.19%。相比之下，直接提示方法(DP)仅达到 44.36%、35.40%和 39.36%的精确率、召回率及 F1 值，原因在于其缺乏针对风电装备领域的术语与复杂关系的优化，难以有效应对专业领域的知识需求。思维链方法(COT)在逐步推理下虽将 F1 值提升至 51.42%(精确率为 56.42%、召回率为 47.19%)，但仍未针对风电装备领域进行深入适配，导致对多层次关系的解析能力不足。Sciphi Triplex (F1=52.28%)同样缺少专业知识微调，无法充分捕捉风电装备中的复杂语义；而领域微调提示方法(DFP)通过对提示进行适配，F1 值达到 76.15%，表明领域化策略对性能提升的有效性，但与 LLM-KG 仍有一定差距。LLM-KG 通过领域微调和增量学习机制，有效捕捉了风电装备专业领域的复杂关系与术语，使其在复杂关系抽取任务中展现出更高的灵活性与精确度，最终在

该专业数据集上取得了最佳结果。

3.4.3 公开域实验结果

将本文的模型与基准模型在公开域 DDI 数据集上进行三元组完全匹配的精确率、召回率以及 F1 值的比较，最后得出的结果如下表 10 所示。

表 10 公开域模型效果对比

Table 10 Comparison of domain-specific model performance

数据集	构建方式	精确率	召回率	F1 值
DDI	DP	48.21	39.10	43.18
	COT	62.24	52.98	57.24
	DFP	84.38	74.93	79.37
	Sciphi Triplex	59.45	50.30	54.49
	LLM-KG (本文)	85.78	76.39	80.81

在公开域 DDI 数据集上，LLM-KG 以 85.78%的精确率、76.39%的召回率和 80.81%的 F1 值取得最优结果，显示出其在生物医学领域复杂关系抽取中的稳健性与高效性。相较之下，直接抽取方法(DP)的 F1 值仅为 43.18%，因未对生物医学领域的术语与交互关系进行任何微调，难以精准识别并匹配多层次实体与关系；Sciphi Triplex 虽具备通用三元组抽取能力，但 F1 值仅为 54.49%，同样缺乏针对生物医学专业知识的适配。思维链方法(COT)通过逐步推理在一定程度上提高了 F1 至 57.24%，但其推理逻辑并未深入结合领域术语，故对复杂药物交互关系的抽取仍有局限。领域微调抽取方法(DFP)在精确率与召回率上均有显著提升，F1 值达 79.37%，说明对生物医学领域提示信息的优化确能增强模型适应性；然而，与 LLM-KG 相比仍有一定差距。LLM-KG 在该公开域数据集上的成功表明，通过微调与增量学习策略有效捕捉领域专业术语及交互模式，不仅提升了对复杂关系的解析深度，也增强了模型在生物医学场景下的稳定性和实时性。

3.4.4 工业知识图谱挑战应对分析

从前述实验结果可见，本文提出的 LLM-KG 模型在应对工业知识图谱构建过程中常见的标注样本稀缺、文档多源异构以及语义结构复杂等核心挑战时，展现出良好的适应性、扩展性与鲁棒性。具体分析如下：

(1) 标注样本稀缺性问题应对能力：工业领域知识获取成本高昂，手工标注困难，数据规模通常较小。WPED 数据集的训练样本数量仅为 7234 条，远低于开放领域如 DDI 数据集的规模。LLM-KG 在 WPED 上仍取得了 83.19%的精确率、73.80%的召回率与 78.19%的 F1 值，明显优于未进行领域适配的 DP(F1=39.36%)和 COT(F1=51.42%)模型。这表明，借助 LoRA 技术实现参数高效微调后，LLM-KG 能够在小样本条件下高效迁移并学习领域知识。

(2) 文档多源异构问题的应对能力：工业知识广泛

分布于格式多样、来源复杂的文档中，常伴随结构风格差异大、实体关系表达冗余及不一致等问题。WPED 和 DDI 数据集均包含多源文档数据，以 DDI 为例，其数据来自 1017 份文档，文档间实体与关系存在冗余、命名歧义、结构差异等挑战。LLM-KG 引入自适应提示模板机制与语义分块策略，统一不同文档结构下的语义表示；同时结合轻量级领域大模型，对候选实体之间的语义相似度与一致性进行向量级对齐与判断，提升了实体与关系融合的精度，精确率、召回率和 F1 指标均明显优于 Triplex、DFP 等对比模型，验证了其在多源异构知识融合方面的优势。

(3) 语义结构复杂问题应对能力：工业文本常涉及复杂语义结构，如嵌套实体、链式因果关系等。例如表 6 所示句子：“检测算法识别出主轴承润滑异常，影响风机运行稳定性，需要更换润滑系统组件”，同时包含嵌套实体及关系因果链条。传统模型如 COT 与 Triplex 在面对此类语句时容易出现结构解析不足、三元组缺失或冗余等问题。而 LLM-KG 凭借增强的语义理解能力与上下文建模机制，能够准确识别嵌套实体及其关系，在 WPED 上表现出良好的结构解析能力；同时在 DDI 数据集上也取得了 80.81% 的 F1 值，进一步验证了其在跨语义复杂度场景中的泛化性与稳定性。

3.5 工程应用案例

3.5.1 风电装备知识图谱构建

为验证所提出的 LLM-KG 模型在工业实际场景中的适用性与有效性，本文依托企业真实项目，以风电装备运维场景为典型应用背景，采集风电装备运行报告、故障案例库、技术手册与维修规范等多源异构文本数据，开展知识图谱构建与效果验证。

在知识构建阶段，首先基于 GPT-4 自动生成的小规模高质量标注样本，结合 LoRA 技术对轻量级语言模型进行风电领域微调，从而显著提升模型对行业术语和隐含语义的识别能力。微调后的模型能够准确抽取包括“故障部件”、“故障原因”、“故障现象”与“维修措施”等关键领域实体，并自动构建其之间的语义关系三元组。

在知识增量融合阶段，系统借助向量数据库实现跨文档实体的高效召回，并利用领域轻量级大模型进行语义筛选与三元组一致性验证，有效过滤冗余与错误关系，保证图谱更新的准确性与一致性，从而支持知识图谱的动态演化与持续优化。

3.5.2 风电装备知识图谱可视化

考虑到风电装备普遍采用基于 BOM (Bill of Materials, 物料清单) 的层级化结构体系，本文进一步设计并实现了一套融合 GBOM (General BOM, 通用物料清

单) 层级结构的知识图谱可视化系统，其架构如图 10。




图 10 基于 GBOM 的风电装备知识图谱可视化

Fig.10 Visualization of Wind Power Equipment Knowledge Graph Based on GBOM

该系统将装备的物理层级结构与图谱的语义结构深度融合，构建支持分层导航、语义联动与知识追溯的一体化可视化交互平台。用户可通过左侧 GBOM 树状导航栏快速定位目标结构单元(如“轮毂”)，系统将自动调用 Neo4j 图数据库，完成对应子图的查询与可视化渲染。

如图 11 所示，以“轮毂”为中心节点的知识子图直观呈现了其关联的故障类型、成因分析、维修策略与运行参数等语义实体，并通过边标签清晰标注各类语义关系，帮助用户快速理解知识关联路径与上下文。




图 11 轮毂相关知识图谱

Fig.11 Knowledge Graph Related to the Hub Assembly

为提升用户的知识探索体验，系统支持节点级交互响应。当用户点击“轮毂”节点时，系统将弹出对应的知识信息窗口(如图 12)，展示该实体的类型、标签、核心属性及相关实体列表。所有关联实体均以超链接形式展示，便于用户进一步跳转查看详细信息。例如，当用户点击“轮毂组成”链接时，系统将自动关闭当前窗口，并弹出“轮毂组成”知识窗口(如图 13)，呈现更细粒度的结构分解信息及其上下文知识，支持用户进行多级结构溯源与语义挖掘。



图 12 轮毂信息窗口

Fig.12 Knowledge window of the hub



图 13 轮毂组成信息窗口

Fig.13 Knowledge Window of the composition of the Hub

综上所述,该系统不仅实现了面向风电装备的图谱信息层级化组织与可视化呈现,还显著提升了领域知识的交互性、可访问性与可解释性。通过该系统,可为实际运维场景中的故障诊断、维修决策与知识服务提供坚实支撑,进一步验证了 LLM-KG 方法在工程实践中的可落地性与实用价值。

4 结论

本文针对工业领域知识图谱构建面临的标注样本稀缺、文档多源异构、语义结构复杂等核心挑战,创新性地提出了基于大语言模型的领域知识图谱增量构建方法 LLM-KG。本方法通过以下技术突破实现了高效、精准的领域知识图谱构建:首先,在数据层面,创造性采用 GPT-4 模型自动生成高质量标注数据,不仅有效缓解了工业领域标注数据稀缺的痛点,更显著提升了训练样本的语义覆盖度和领域适应性。在模型优化方面,创新性地应用 LoRA 技术对轻量级大模型进行领域适配,在保持模型轻量化的同时,大幅提升了其对专业术语和复杂语义关系的理解与抽取能力。其次,在算法层面,提出了基于语义完整性的信息块划分策略,通过优化上下文语义单元表示粒度,实现了实体与关系的高效关联。进一步结合向量数据库技术,构建了 Top-k 候选实体高效召回机制,并创新性地引入大语言模型进行语义一致性校验。实验验证方面,在 DDI 医学标准数据集和自建 WPED 风电装备专业数据集上的对比实验表明,LLM-KG 方法在准确率、召回率和 F1 值上显著优于传统方法。基于研究成果,我们成功研发了风电装备知识图谱可视化交互系统,在实际工程项目中实现了知识的高效管理与智能应用。

尽管 LLM-KG 在知识抽取与增量构建方面表现出色,但当前方法依赖多次大模型调用,导致时间开销较

高,未来将探索提示工程优化与小模型协同推理,减少计算延迟。

参考文献

- [1] 王光,姜皓.融合多视图对比学习和知识图谱的推荐算法[J/OL]. 计算机系统应用,1-11[2025-04-11].<https://doi.org/10.15888/j.cnki.csa.009853>.
WANG G, JIANG H. Recommendation algorithm integrating multi-view contrastive learning and knowledge graph[J/OL]. Computer Systems and Applications, 1-11 [2025-04-11].<https://doi.org/10.15888/j.cnki.csa.009853>.
- [2] 陈俊臻,王淑莹,罗浩然.融合大模型微调与图神经网络的知识图谱问答[J]. 计算机工程与应用,2024,60(24):166-176.
CHEN J Z, WANG S Y, LUO H R. Combining Large Model Fine-Tuning and Graph Neural Networks for Knowledge Graph Question Answering[J]. Computer Engineering and Applications, 2024, 60(24): 166-176.
- [3] Tian X, Liu B, Yang J, et al. Knowledge Graph Enhanced Interactive Fault Diagnosis O&M Approach Based on Large Models of Electrical Power[C]//2024 4th Power System and Green Energy Conference (PSGEC).0[2025-04-21]. DOI:10.1109/PSGEC62376.2024.10721152.
- [4] 孙熠衡,刘茂福.基于知识提示微调的标书信息抽取方法[J]. 计算机应用,2025,45(04):1169-1176.
SUN Y H, LIU M F. Tender information extraction method based on prompt tuning of knowledge[J]. Journal of Computer Applications, 2025, 45(4): 1169-1176.
- [5] Gao D, Ma Y, Liu S, et al. FashionGPT: LLM instruction fine-tuning with multiple LoRA-adaptor fusion[J]. Knowledge-Based Systems, 2024, 299(000):10. DOI:10.1016/j.knosys.2024.112043.
- [6] Li Y, Ji M, Chen J, et al. A large language model-based building operation and maintenance information query[J]. Energy and Buildings, 2025, 334(000).DOI:10.1016/j.enbuild.2025.115515.
- [7] 苑中旭,李理,何凡,等.融合思维链与知识图谱的中医问答模型[J]. 计算机工程与应用,2025,61(04):158-166.
YUAN Z X, LI L, HE F, et al. Traditional Chinese Medicine Question Answering Model Based on Chain-of-Thought and Knowledge Graph[J]. Computer Engineering and Applications, 2025, 61(4): 158-166.
- [8] 李晓理,刘春芳,耿劲坤.知识图谱与大语言模型协同共生模式及其教育应用综述[J]. 计算机工程与应用,2025,61(15):1-13.
LI X L, LIU C F, GENG S K. Survey of Collaborative Symbiosis Mode Between Knowledge Graph and Large Language Model and Its Education Application[J]. Computer Engineering and Applications, 2025, 61(15): 1-13.
- [9] 姚奕,陈朝阳,杜晓明,等.多模态知识图谱构建技术及其在军事领域的应用综述[J]. 计算机工程与应用,2024,60(22):18-37.
YAO Y, CHEN Z Y, DU X M, et al. Survey of Multimodal Knowledge Graph Construction Technology and Its Application in Military Field[J]. Computer Engineering and Applications, 2024, 60(22): 18-37.
- [10] Su C, Han Y, Tang X, et al. Knowledge-based digital twin system: Using a knowledge-driven approach for manufacturing process modeling[J]. Computers in Industry, 2024:159/160. DOI:10.1016/j.compind.2024.104101.
- [11] Zhang T, Wu F, Katiyar A, et al. Revisiting few-sample BERT fine-tuning[J]. arXiv preprint arXiv: 2006.05987, 2020.

- [12] 栗伟,赵大哲,李博,等.CRF 与规则相结合的医学病历实体识别[J].计算机应用研究,2015,32 (04):1082-1086.
LI W,ZHAO D Z,LI B, et al. Combining C R F and rule based medical named entity recognition[J]. Application Research of Computers,2015,32 (04):1082-1086.
- [13] Kage P, Andreadis P. Class Introspection: A Novel Technique for Detecting Unlabeled Subclasses by Leveraging Classifier Explainability Methods[J]. arXiv preprint arXiv:2107.01657, 2021.
- [14] Zhao T , Liu H , Wu Q ,et al.BiGCNN: Bidirectional Gated Convolutional Neural Network for Chinese Named Entity Recognition[J].Springer, Cham, 2020,12112:502-518
- [15] Eliguzel N , Cetinkaya C , Dereli T .Application of named entity recognition on tweets during earthquake disaster: a deep learning-based approach[J]. Soft computing: A fusion of foundations, methodologies and applications, 2022(26-1): 395-421
- [16] Fudholi D H , Nayoan R A N , Hidayatullah A F ,et al.A HYBRID CNN-BILSTM MODEL FOR DRUG NAMED ENTITY RECOGNITION[J].Journal of Engineering Science and Technology, 2022, 17(1):730-744
- [17] Wang J , Xu W , Fu X ,et al. ASTRAL: Adversarial Trained LSTM-CNN for Named Entity Recognition[J]. Knowledge-Based Systems, 2020:105842. DOI:10.1016/j.knosys.2020.105842.
- [18] 马裕鹏,张明,李志强,等.融合外部知识增强多模态命名实体识别[J/OL].计算机工程与应用,1-14[2025-04-11].<http://kns.cnki.net/kcms/detail/11.2127.TP.20250312.1601.017.html>. External Knowledge Fusion-Enhanced Multimodal Named Entity Recognition[J/OL]. Computer Engineering and Applications, 1-14 [2025-04-11]. <http://kns.cnki.net/kcms/detail/11.2127.TP.20250312.1601.017.html>.
- [19] Permamn C J, Gaston D R, Andrš D, et al. MOOSE: Enabling massively parallel multiphysics simulation[J]. SoftwareX, 2020, 11: 100430.
- [20] Fasen-Hartmann V, Mayer C. Empirical spectral processes for stationary state space models[J]. Stochastic Processes and their Applications, 2023, 155: 319-354.
- [21] Zhi Kang J K, Gaurav, Tan S Y, et al. Efficient deep learning pipelines for accurate cost estimations over large scale query workload[C]//Proceedings of the 2021 International Conference on Management of Data. 2021: 1014-1022.
- [22] Zhang Z, Zhao Y, Gao H, et al. LinkNER: linking local named entity recognition models to large language models using uncertainty[C]//Proceedings of the ACM Web Conference 2024. 2024: 4047-4058.
- [23] Hu Y, Chen Q, Du J, et al. Improving large language models for clinical named entity recognition via prompt engineering[J]. Journal of the American Medical Informatics Association, 2024, 31(9): 1812-1820.
- [24] Dagdelen J, Dunn A, Lee S, et al. Structured information extraction from scientific text with large language models[J]. Nature Communications, 2024, 15(1): 1418.
- [25] De S, Sanyal D K, Mukherjee I. Fine-tuned encoder models with data augmentation beat ChatGPT in agricultural named entity recognition and relation extraction[J]. Expert Systems with Applications, 2025, 277: 127126.
- [26] Pimpalgaonkar S, Tremelling N, Colegrove O. Triplex: a SOTA LLM for knowledge graph construction[EB/OL]. (2024)[2025-03-09]. <https://huggingface.co/sciphi/triplex>.
- [27] 谢明华.基于大模型的信息领域知识图谱自动构建与检索技术[J].电讯技术,2024,64(08):1228-1234.DOI:10.20079/j.issn.1001-893x.240422003.
XIE M H. Automatic construction and retrieval technology of knowledge graph in electronic information domain based on large language models[J]. Telecommunication Engineering, 2024, 64(08): 1228-1234. DOI:10.20079/j.issn.1001-893x.240422003.
- [28] 张昆, 张永伟, 吴永城, 等. 基于大模型的设备故障知识图谱自动构建方法[J]. 计算机与现代化, 2024 (11): 46.
ZHANG K, ZHANG Y W, WU Y C, et al. Automatic construction method of equipment fault knowledge graph based on large language models[J]. Computer and Modernization, 2024(11): 46.
- [29] 董磊, 吴福居, 史健勇, 等. 基于大语言模型的施工安全多模态知识图谱的构建与应用[J]. 计算机工程与应用, 2025,61(9): 325-333.
DONG L, WU F J, SHI J Y, et al. Construction and Application of Multimodal Knowledge Graph in Construction Safety Field Based on Large Language Model[J]. Computer Engineering and Applications, 2025, 61(9): 325-333.
- [30] PAN S R, LUO L H, WANG Y F, et al. Unifying Large Language Models and Knowledge Graphs: A Roadmap[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599.
- [31] Tumasyan A, Adam W, Andrejkovic J W, et al. Search for invisible decays of the Higgs boson produced via vector boson fusion in proton-proton collisions at $\sqrt{s} = 13$ TeV[J]. Physical Review D, 2022, 105(9): 092007.
- [32] Liu C X, Wang G, Dvir T, et al. Tunable superconducting coupling of quantum dots via Andreev bound states in semiconductor-superconductor nanowires[J]. Physical review letters, 2022, 129(26): 267701.